

# Neuronové sítě

Jakub Mamica

19. května 2024

## Abstrakt

Tato práce se zabývá implementací neuronových sítí pro zpracování datasetu určeného pro analýzu sentimentu vět z recenzí produktů, filmů a restaurací. Úvodem jsou představeny neuronové sítě jako pokročilé výpočetní systémy napodobující způsob zpracování informací v lidském mozku s vrstvami umělých neuronů. Praktická aplikace zahrnuje různé sektory, demonstruje rozsáhlé a různorodé využití neuronových sítí v technologii pro AI a strojové učení, finančnictví pro predikci tržních trendů, automobilový průmysl pro vývoj autonomních vozidel a zákaznické služby prostřednictvím chatbotů. Byly vyvinuty dva odlišné modely pomocí Keras a TensorFlow v prostředí Jupyter Notebooks, testované na přesnost a ztrátovost, což zdůrazňuje výzvy a efektivitu každého modelu při zpracování daného datasetu.

## 1 Úvod

V rámci práce jsou zpracovávány neuronové sítě zpracovávající dataset vytvořený pro článek "From Group to Individual Labels using Deep Features" od Kotzias a spol.<sup>1</sup> Obsahuje věty označené jako pozitivní nebo negativní podle sentimentu, které byly extrahovány z recenzí produktů, filmů a restaurací. V následující části si přiblížíme termín neuronové sítě a jejich využití, jako základ pro praktickou část.

Neuronové sítě jsou pokročilé výpočetní systémy, které napodobují způsob zpracování informací v lidském mozku. Tvoří je vrstvy umělých neuronů propojených vzájemně váhovými spoji, které se adaptují a učí na základě dostupných dat. Tento proces umožňuje neuronovým sítím vyvíjet schopnosti bez potřeby explicitního programování.

Využití neuronových sítí je rozsáhlé a různorodé, pronikající do mnoha odvětví a oblastí. V technologickém sektoru jsou základem pro rozvoj umělé inteligence a strojového učení, kde se používají pro analýzu velkých dat, rozpoznávání obrazu a zpracování přirozeného jazyka. Ve finančním sektoru pomáhají modelovat a předpovídat tržní trendy, což umožňuje lepší rozhodování a risk management. V automobilovém průmyslu jsou klíčové pro vývoj autonomních vozidel, kde zpracovávají obrovské množství senzorických dat v reálném čase, aby bezpečně navigovaly dopravním prostředím.

V medicíně neuronové sítě revolucionizují diagnostiku a léčbu nemocí tím, že umožňují přesnější vyhodnocení medicínských obrazových dat, jako jsou rentgeny nebo MRI skeny. V oblasti zákaznických služeb automatizují a zlepšují interakce s klienty prostřednictvím chatbotů a virtuálních asistentů, kteří jsou schopni zpracovávat a reagovat na přirozený jazyk.

Tyto aplikace demonstrují flexibilitu a široký rozsah možností, které neuronové sítě nabízejí, a zároveň naznačují, jak mohou tyto technologie přetvářet průmyslové a profesionální prostředí, zvyšovat efektivitu a otevírat nové možnosti pro inovace ve všech sektorech.

Nyní přejdeme k praktické části popisující vznik modelů a jejich v

## 2 Metody

Pro tvorbu neuronových sítí jsme využili prostředí poskytnuté serverem `jupyter.vse.cz` a python knihoven Keras a Tensorflow. Sítě, jak již bylo naznačeno byly napsány v pythonu a spouštěny v rámci Notebooků na serveru `jupyter.vse.cz`. Byly vytvořeny dvě sítě reflektující svými vlastnostmi a výsledky dva různé přístupy k vytváření modelu za zpracování již dříve uvedených dat.

Kód sítí se zásadně neliší, největší rozdíly jsou v samotných modelech. Nejprve v kódu importujeme potřebné knihovny. Poté načteme data od Amazonu Yelpu a Imdb, data spojíme do jedné skupiny, jelikož jejich důvod není pro kontext práce relevantní. Data následně zpracujeme pro práci s modelem a rozdělíme na trénovací (75 % z celkových dat) a testovací (zbylých 25 %).

Následují samotné modely, část, která obě sítě nejvíce definuje a v které se nejvíce liší.

První model (dále model-1) je sekvenční a má pouze dvě Dense vrstvy. První o 50 neuronech a druhou o 2. Následně se model kompiluje, určuje se ztrátová funkce, optimalizační algoritmus a sledovaná metrika.

Model-1:

```
model = Sequential()

model.add(Dense(50, input_shape=(100,), activation='relu'))

model.add(Dense(2, activation='softmax'))

model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
```

Druhý model (dále model-2) je sekvenční a obsahuje pět vrstev různých typů. První je Embedding vrstva převádějící celočíselné indexy na husté vektory určité velikosti. Následuje LSTM vrstva s 64 neurony a četností vyřazení 0.2. Další je Dense vrstva o 64 neuronech, po ní Dropout vrstva s hodnotou 0,5 (stejně jako ve vrstvě LSTM i zde vyřazování určité části neuronů slouží za účelem model nepřeučit). Poslední vrstva Dense s 2 neurony. Kompilace vypadá obdobně jako u předchozího modelu-1.

Model-2:

```
model = Sequential()

model.add(Embedding(input_dim=5000, output_dim=64, input_length=100))

model.add(LSTM(64, dropout=0.2, recurrent_dropout=0.2))

model.add(Dense(64, activation='relu'))

model.add(Dropout(0.5))
```

```
model.add(Dense(2, activation='softmax'))

optimizer = Adam(learning_rate=0.001)

model.compile(loss='categorical_crossentropy', optimizer=optimizer, metrics=['accuracy'])
```

Následuje Samotné trénování modelů. Vzhledem ke specifikám modelů a času trénování byl model-1 trénován 50 epoch a model-2 20 epoch.

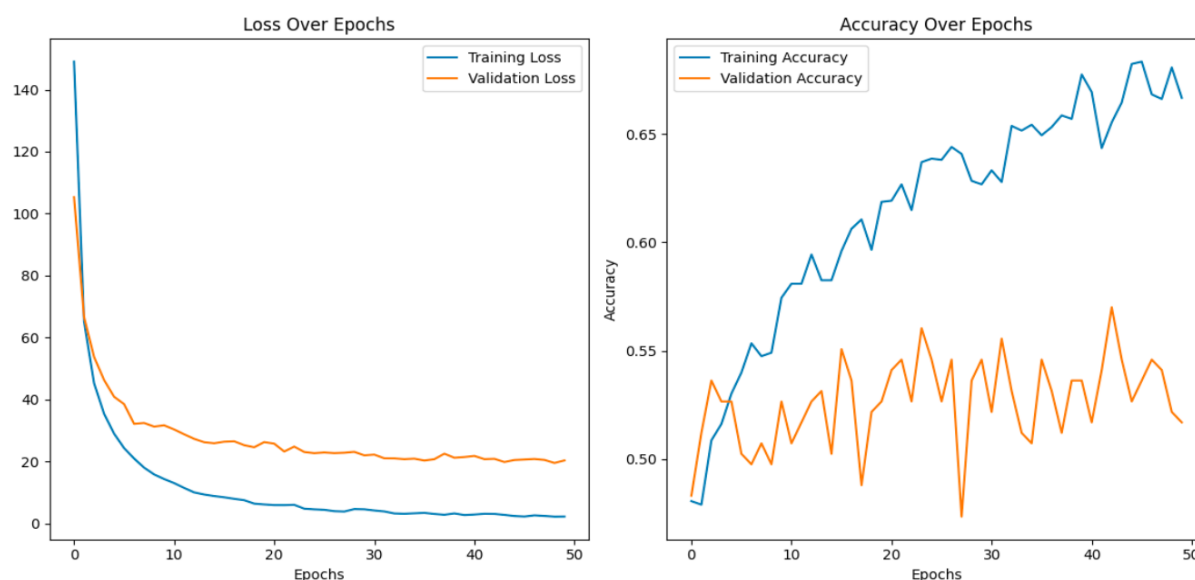
V kódu následuje vypsání výsledků modelu na trénovacích a testovacích datech, vypisuje se jak přesnost, tak ztrátovost. Tyto výsledky jsou vizualizovány v grafech.

Tento kód byl převeden do Notebooků a spuštěn.

### 3 Výsledky

Výsledky obou sítí jsou nejlépe reprezentované grafy obsahující ztrátovost (vlevo) a přesnost (vpravo), grafy také porovnávají výsledky trénovacích a testovacích dat (modrá linie trénovací data, oranžová testovací).


Model-1:



Graf model-1 (vlastní zpracování)

Jak lze z grafu pozorovat model dosahuje relativně bídých výsledků. Konkrétně po 50 epochách dosáhl trénovací přesnosti 0,6841 a testovací přesnosti 0,5328. Což když to zasadíme do kontextu, kdy data jsou recenze, které jsou buď kladné či pozitivní znamená, že bychom náhodným tipováním měli mít přesnost 0,5. Od té se při testování tato síť nijak výrazně nevzdálila.

Model-2:



Graf model-2 (vlastní zpracování)

Model-2 má daleko lepší výsledky. V rámci trénování dosáhl lepších výsledků jak model-1. Při testování se ale ztrátovost v průběhu epoch obrátila a místo klesání začala stoupat. Jinak i testovací výsledky dopadly lépe jak u modelu-1. Přesnost při trénování dosáhla 0,9748 a při testování 0,8185.

## 4 Diskuze

Jak je očividné ani jeden z modelů není optimální pro daná data.

Model-1 dosahuje nízké přesnosti a pro účely posuzování zadaných dat je nedostačující. Je to dané jeho jednoduchým designem neposkytující dostatečnou komplexnost nutnou k lepším výsledkům.

Model-2 už se blíží svými lepšími výsledky k pomyslnému optimu. Z grafu ztrátovosti plyne že u sítě došlo k přeučení. Tomu by se dalo čelit úpravou drop ratu v LSTM a Dropout vrstvách, či přidáním dalších vstupních dat.

Pokud by se mělo v práci pokračovat model-2 poskytuje lepší startovní pozici.

## 5 Závěr

V rámci práce byly zpracovány dvě neuronové sítě a přiblížen pojem neuronové sítě v kontextu dnešního světa. Obě sítě dohromady ilustrovaly rozdíly ve fungování různě komplexních neuronových sítí zpracováním data setů obsahujícího věty označené jako pozitivní nebo negativní podle sentimentu, které byly extrahovány z recenzí produktů, filmů a restaurací.

## References

Kotzias et. al.,. KDD 2015. *From Group to Individual Labels using Deep Features*. Online. In: dkotzias.com . Srpen 2015. Dostupné z: <https://dkotzias.com/papers/GICF.pdf> . [citováno 2024-05-19].